

반려견 질병 증상 상담 챗봇

LLM을 연동한 외부 문서 기반 RAG 질의응답 시스템

목차

01 프로젝트 개요

04 RAGAS 평가

02 데이터 수집 & 전처리

05 RAG 구축

03 임베딩 & 벡터DB


06 Streamlit 시현

프로젝트 개요


- 반려견 증상을 입력하면, 관련 수의학 지식을 바탕으로 상담을 제공하는 RAG 챗봇 개발



30,000+ 수의학 문서
및 Q&A 데이터



LLM + RAG + Ensemble
검색 구조



RAGAS 기반
객관적인 성능 평가



Streamlit UI
실제 사용 가능한 챗봇 구현

문제 인식 & 해결방안

문제 1 신뢰할 수 있는 수의학 정보 찾기 어려움

→ 수의학 서적 + 실제 상담 데이터 기반 답변 (모든 답변에 출처 문서 표기)

문제 2 검색엔진은 키워드 위주여서 맥락있는 상담이 어려움

→ Ensemble 검색(Vector Search + BM25) 문맥기반 탐색 제공

데이터 수집 & 전처리

데이터 구성

- AIHub의 <반려견 성장 및 질병관련 말뭉치 데이터> 사용
 - 수의학 지식 데이터: 수의학 서적 및 논문에서 발췌한 전문 설명문

전문 수의학서적 저작권 해결

업무협약서

비영리재단법인인 (사)한국동물보호협회는 "2024년 초기데이터 생태계 조성 사업"에서 ㈜비즈니스랩과 20년 반려동물 데이터 파생 수익성 운영을 위해 필요한 전문서적의 저작권 이용에 관한 자문과 기술적 지원을 제공할 것을 협약합니다.

2024년 04월 17일

㈜비즈니스랩

(사)한국동물보호협회

서적, 논문 데이터 수집



수의학 서적 데이터

데이터 구성(json)
: 제목, 저자, 출판사, 진료과, 질병 설명

데이터 구성

- AIHub의 <반려견 성장 및 질병관련 말뭉치 데이터> 사용
 - Q&A 데이터: 수의사가 직접 작성한 질의응답 데이터 실제 상담 기록
- 대한 수의사회에 소속된 각 병원에서 기보유하고 있는 EMR차트 내 상담내용을 토대로 수의사가 직접 답변을 작성
- 펫앤라이프에서 기보유한 쿠팡 로켓펫닥터 질문 내용을 토대로 수의사가 질문과 답변을 직접 작성)



Q&A 데이터

데이터 구성 : 생애주기(자견, 성견, 노령견), 진료과, 질병명, 질문, 답변

데이터 전처리 & 청킹

- 청킹 : 대규모 문서를 효과적으로 검색하기 위한 핵심 전략
 - 수의학 서적 데이터
 - * RecursiveCharacterTextSplitter
 - * 청크 크기 500자, 오버랩 100자
 - * 구분자 ['\n\n', '\n', '.', '!', '?', ',', ' ', '']
 - Q&A 데이터
 - * RecursiveCharacterTextSplitter
 - * 청크 크기 800자, 오버랩 50자
 - * 구분자 ['\n\nA:', 'Q:', '\n\n', '\n', '.', ' ', '']



임베딩 & Vector DB

ChromaDB 구축

OpenAI text-embedding-3-small

- 1536 차원 벡터의 고성능 임베딩
- 비용 발생



BGE-M3 (BAAI/bge-m3)

- 허깅페이스의 M3 시리즈
- 다국어 기반, 고성능 임베딩
- 오픈 소스



→ 두 종류의 임베딩 모델을 사용해 각각 Chroma DB 구축

RAGAS 평가

어떤 임베딩 모델 & 리트리버를 사용해야 할까?

선택할 수 있는 모델 & 리트리버 종류 & 파라미터 조합 多,,

→ 각 조합의 성능 **정량적 측정 by RAGAS !**

What is RAGAS?

- 리트리버 성능을 점수화하는 평가 프레임워크
- 4가지 주요 지표를 활용해 리트리버의 성능을 수치로 비교

합성 테스트 데이터셋 생성

LLM을 이용해 문서에서 10개의 QA(질문-문맥-응답) 샘플 추출

→ 정답과 문맥을 함께 저장해 평가용 데이터셋 구축

user_input	reference
골관절염에서 IL-1과 TNF-α가 연관된 이유는 무엇인가요?	이 인자들은 연골세포와 활막의 섬유아세포로부터 단백질 분해 효소의 생성을 촉진시키며, 이러한 효소가 콜라겐과
성견이 되었는데 강아지의 유치가 송곳니에 세 개 남아 있습니다. 이 유치는 병원에서 제거해야 하나요?	강아지가 성견이 라면, 이미 유치가 자연스럽게 빠질 시기는 지나간 상태입니다. 따라서 병원에 내원하셔서 진정 과?
신장 미부에서 발견된 종양의 장축 직경은 얼마입니까?	종양의 장축 직경은 6cm였습니다.
고구마, 복어, 계란 노른자만으로 강아지의 사료를 완전히 대체할 수 있나요?	고구마, 복어, 계란 노른자만으로는 강아지가 필요로 하는 다양한 영양소를 균형 있게 제공하기 어려우므로 사료를 5
강아지가 시원한 곳에 있을 때 헉헉거림이 완화되지만 곧 다시 나타나는 이유는 무엇인가요?	헉헉거림은 체온 조절, 흥분, 또는 호흡곤란 등 세 가지 주요 원인 때문일 수 있습니다. 체온 조절이나 흥분이 원인이
Dirofilaria immitis는 어떤 슈퍼패밀리에 속합니까?	Dirofilaria immitis는 슈퍼패밀리 Filarioidea에 속합니다.
강아지의 복부가 부풀어 오르고 식욕 부진이 있을 때 어떻게 해야 하나요?	혈액 검사, 방사선 촬영, 복부 초음파 검사를 통해 보다 정확한 진단을 받으실 것을 권장합니다.
중성화 수술이 이루어지지 않은 경우 건강상 유의해야 할 점이 있나요?	중성화 수술이 이루어지지 않은 경우 암 발생 위험이 증가할 수 있으니 유념하시기 바랍니다.
11세의 중성화하지 않은 암컷 반려견이 구토와 기력 저하 증상을 보일 때 어떤 건강 문제가 의심되며 어떤 검사가 필요한가요?	중성화하지 않은 노령 암컷 반려견에서 구토와 기력 저하가 있을 경우 자궁축농증 등 생식기 감염이나 종양이 의심된
참진드기에 의한 기생충 문제를 예방하기 위해 어떤 치료법을 사용해야 하나요?	가급적 약욕 치료를 권장드리며, 기존의 기생충 예방약을 사용하시는 것도 좋은 방법입니다.

후보 임베딩 모델- 2종류

Open AI Embeddings

허깅페이스의 Bge-m3

후보 리트리버 - 4종류

Dense Retriever

코사인 유사도 기반 검색

MMR Retriever

다양성 & 관련성 함께 고려

BM25 Retriever

단어 기반(Frequency-based) 검색

Ensemble Retriever

Dense + BM25

(각 리트리버의 기본 파라미터 사용)

RAGAS 평가 프로세스

1. 2개의 VectorDB * 4개의 리트리버
→ 총 **8개의 RAG** 구성
2. 동일한 질문 10개를 각 RAG에 입력
→ 8가지 답변 세트 생성
3. **각 답변을 테스트셋(Ground Truth)과 비교**
4. **RAGAS의 평가지표를 이용해 성능 측정**

<RAGAS의 4가지 평가지표>



Context Recall

검색 시스템이 관련된 모든 문서를 찾아낸 정도



Context Precision

검색된 문서가 질문과 얼마나 관련 있는지 평가



Faithfulness

생성된 답변이 검색된 문서 내용에 충실한 정도



Answer Relevancy

생성된 답변이 사용자 질문에 적절한지 평가

RAGAS 성능 비교 결과

OpenAI Embeddings (text-embedding-3-small)

검색 방식	Context Recall	Context Precision	Faithfulness	Answer Relevancy	평균
Similarity	0.7012	0.7945	0.8834	0.8012	0.7951
MMR	0.7623	0.7756	0.8890	0.8234	0.8126
BM25	0.6745	0.8123	0.8567	0.7734	0.7792
Ensemble	0.7934	0.8234	0.9012	0.8456	0.8409

BGE-M3 (BAAI/bge-m3)

검색 방식	Context Recall	Context Precision	Faithfulness	Answer Relevancy	평균
Similarity	0.7234	0.8123	0.8956	0.8234	0.8137
MMR	0.7856	0.7934	0.9012	0.8456	0.8315
BM25	0.6934	0.8345	0.8723	0.7923	0.7981
Ensemble	0.8123	0.8456	0.9234	0.8678	0.8623

Bge-m3 임베딩 모델
&
앙상블 리트리버
조합 채택

RAG 구축

1. 질의 요약 (Query Rewriting)

```
def get_rewrite_prompt():  
    return ChatPromptTemplate.from_messages([  
        ("system", ""  
        | 사용자의 질의를 검색에 최적화된 형태로 재작성합니다.  
        | 핵심 키워드와 의도만을 추출하여 간결하게 표현하세요.  
        | """),  
        ("user", "{user_query}")  
    ])
```

사용자가 입력한 원본 질의

→ rewrite 프롬프트를 통해 핵심 내용만 추출

강아지가 밥을 잘 안 먹고
계속 토해요



강아지 식욕부진 구토

2. 문서 검색(Ensemble Retrieval)

```
def get_retriever(vectorstore, k=5):  
    """앙상블 리트리버 생성  
    Args:  
        vectorstore (Chroma): 벡터스토어 인스턴스  
        user_query (str): 사용자 질의  
        k (int, optional): 검색할 문서 수. Defaults to 5.  
    """  
  
    # 1) 유사도 기반 리트리버  
    vector_retriever = vectorstore.as_retriever(  
        search_kwargs={  
            "k": k  
        },  
        search_type="similarity"  
    )  
  
    with open(r"..\\data\\chunked_docs.pkl", "rb") as f:  
        docs = pickle.load(f)  
  
    # 2) BM25 리트리버  
    bm25 = BM25Retriever.from_documents(docs, k=k)  
  
    # 3) 앙상블 리트리버  
    ensemble_retriever = EnsembleRetriever(  
        retrievers=[vector_retriever, bm25],  
        weights=[0.5, 0.5]  
    )  
  
    return ensemble_retriever
```

Chroma 기반 임베딩 검색기
(Vector Retriever) 생성

키워드 중심의
BM25 검색기 생성


두 검색기(Vector + BM25)를
하나로 결합하여 가중치 기반
Ensemble 검색기 구성

3. 문서 필터링 (Self-Check)

```
def self_check_retriever(question):  
    ...  
    이 함수는 사용자의 질문을 받아 검색된 문서들을 LLM이 검토하게 합니다.  
    LLM은 각 문서가 질문에 도움이 되는지 판단해 KEEP/DROP을 결정합니다.  
    결과적으로 KEEP인 문서만 반환합니다.  
    ...  
  
    #0. mini chain : 문서 keep or drop ?  
    mini_chain = self_check_prompt | llm | StrOutputParser()  
  
    # 1. 문서 검색  
    found_docs = retriever.invoke(question)  
    print(f'검색된 문서 개수: {len(found_docs)}')  
  
    # 2. 문서별로 KEEP/DROP 판단  
    kept_docs = []  
  
    for doc in found_docs:  
        decision = mini_chain.invoke({'question': question, 'doc': doc.page_content})  
        print(f'\n문서 내용: {doc.page_content}\n판단: {decision}')  
  
        if decision.strip().lower() == 'keep':  
            kept_docs.append(doc)  
  
    if len(kept_docs) == 0:  
        print('모든 문서가 Drop되었습니다. 원래 검색된 문서들을 반환합니다.')  
        kept_docs = found_docs # 모든 문서가 Drop되면 원래 검색된 문서 반환  
  
    print(f'\n최종 선택된 문서 개수: {len(kept_docs)}')  
  
    return kept_docs
```

Ensemble 검색기로
문서 5개 검색

LLM이 각 문서와 원본 query의
관련성을 평가해
KEEP / DROP 반환
→ KEEP 문서만 context로 사용



4. 답변 생성 (RAG Generation)

```
# 최종 RAG 체인 실행
question = "10살 된 노령견이 갑자기 밥을 안 먹고 기력이 없는데, 어떤 질환을 의심해야 하나요?"
llm = ChatOpenAI(model="gpt-4.", temperature=0)

rewrite_chain = rewrite_prompt | llm | StrOutputParser()
transformed = rewrite_chain.invoke({'question' : question})

docs = self_check_retriever(transformed)
context = format_docs(docs)

rag_chain = prompt | llm | StrOutputParser()
answer = rag_chain.invoke({"context": context, "question": transformed})
```


질문의 핵심 내용만 추출한
변형된 질의(transformed) 저장

변형된 질의로 문서 검색
→ 검색한 문서 중 질의와
관련이 높은 문서만 문맥(context)화

rag chain 실행, 답변 생성


전체 RAG 파이프라인 흐름

왜 Query Rewrite + Self-Check가 필요한가?




- VectorDB 규모: 약 34600개 청크
→ 단일 검색만으로는 정확한 문서 선별 어려움
- Query Rewriting
질의 전처리(필수적인 정보만 추출, 불필요/중복 표현 제거)
→ 노이즈 감소
- Self-Check Filtering
→ LLM이 검색된 문서와 질의의 실제 관련성 재평가

→ 두 단계의 전처리·검증 과정을 추가해
단일 검색에 비해 RAG 성능 향상



Streamlit 시현

- 문서 없는 질문



- 문서 있는 질문

결론

- ① 수의학 서적 및 논문, 실제 수의사-보호자 상담기록 데이터 기반
-> 도메인 특화 RAG 설계
- ② RAGAS로 모델 및 리트리버 선택 근거 확보




“본 시스템은 수의사를 대체하는 것이 아니라,
보호자가 더 빠르고 정확한 의사결정을 내릴 수 있도록 돕는 ‘보조적 의학 정보 제공 시스템’입니다”

향후 개선 방향

1. 할루시네이션 문제

비상식적 질문에 키워드 매칭으로 근거 없는 의학 답변이 생성되는 한계



향후 개선 방향

2. Multi-modal 구현

이미지 분석이 가능한
" 멀티모달 LLM(GPT-4V 등) " 도입

증상 사진과 텍스트 질문 함께 해석
→ 보다 정확한 상담 제공

3. 동물병원 안내 기능 추가

공공데이터·카카오 지도 API 연동
사용자 위치 기반 동물병원 안내 기능 제공

"가까운 병원은 ○○입니다." + 지도내 위치 표시

감사합니다 !